Leçon 6 : Vérification formelle à l'ère de l'IA

Promesses, retournements, questions ouvertes

Pablo Donato

Logique et Fondements de l'Informatique

Année 2026

Cadre

- Dernière séance ; pas de nouveau concept technique.
- On prend du recul philosophique sur les 6 semaines.

Fil dialectique

- Acte I — la promesse (maths, sûreté, IA safety).
- Acte II — le retournement 2026 (trois fractures).
- Acte III — questions ouvertes, discussion.

Du rêve de Leibniz à la vérification formelle

Leibniz, XVIIe : *characteristica universalis + calculus ratiocinator*

Réalisations :

- seL4 [Kle+09] — noyau OS prouvé
- CompCert [Ler09] — compilateur C certifié
- 4 Couleurs [Gon08], Kepler [Hal+17]

Mais : 20 années-personnes pour seL4, 6 pour CompCert.

Le pari

Garanties *mathématiques* là où l'ingénierie classique n'en offre pas.

Benzmüller [Ben17] : logique d'ordre supérieur comme *meta-logique universelle*.

Du rêve de Leibniz à la vérification formelle
Leibniz, XVIIe : *characteristica universalis + calculus ratiocinator*
Réalisations :
seL4 [Kle+09] — noyau OS prouvé
CompCert [Ler09] — compilateur C certifié
4 Couleurs [Gon08], Kepler [Hal+17]
Mais : 20 années-personnes pour seL4, 6 pour CompCert.
Le pari
Garanties *mathématiques* là où l'ingénierie classique n'en offre pas.
Benzmüller [Ben17] : logique d'ordre supérieur comme *meta-logique universelle*.

Recadrage

- Paysage connu depuis leçon 1, mais présenté ici comme un *pari*.
- Garantie *mathématique* vs. statistique (tests).

Ordres de grandeur du goulot humain

- Preuve math $\approx$ 10–20$\times$ le coût de la rédaction informelle.
- *Calculemus* de Leibniz — à reprendre en clôture.

Question qui structure l'acte I

- Et si l'IA venait lever ce goulot ?

La nouvelle division du travail : l'IA génère, le noyau vérifie

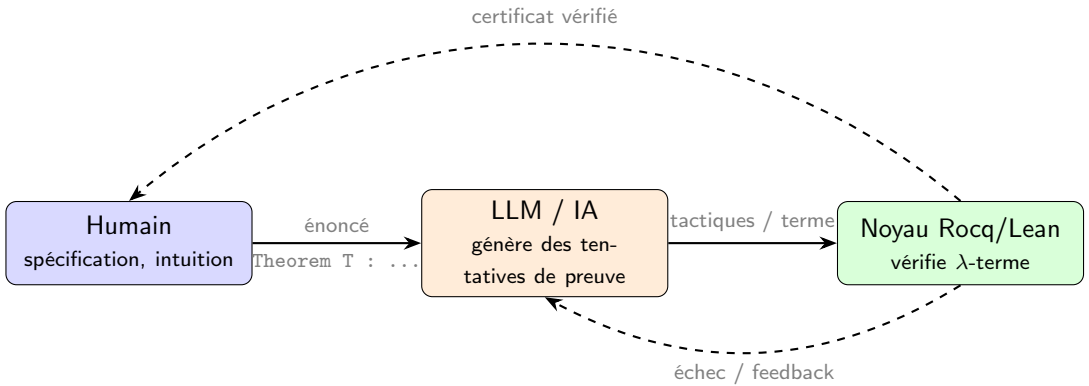

- **Autoformalisation** : informel → Rocq/Lean [Buz25]
- **Tactic search** : AlphaProof [Dee24]
- **L'IA propose, le noyau dispose**

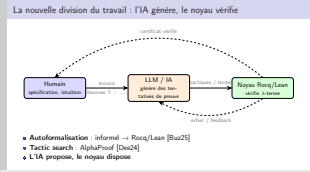

Asymétrie à souligner

- LLM faillible : hallucinations, lemmes inventés → sans conséquence.
- Noyau rejette tout λ-terme mal typé.
- Inédit parmi les applications d'IA : pas besoin de faire confiance au modèle.

Pont leçon 5

- `Fixpoint` bien typé ⇒ terminaison garantie, peu importe l'auteur.

Nuance à glisser

- Division du travail robuste *en apparence* — acte II reviendra dessus.

Mathématiques formalisées : l'appétit de l'IA

Avigad [Avi23] — *tournant formel*

Buzzard [Buz25 ; 25] — après le calcul, le *raisonnement* ?

Jalons :

- Liquid Tensor [al21] / Mathlib
- AlphaProof, IMO 2024 [Dee24]
- **2026** : problèmes d'Erdős [nat26] résolus par Aristotle [Ari26], Aletheia [Goo26]

Severini [Sev26]

≈ 0,05% des maths formalisées.
L'IA a faim de corpus vérifié : la formalisation devient *application phare*.

Massot [Mas21] : outil, pas substitut.

Mathématiques formalisées : l'appétit de l'IA
Avigad [Avi23] — tournant formel
Buzzard [Buz25 ; 25] — après le calcul, le raisonnement ?
Jalons :
Liquid Tensor [al21] / Mathlib
AlphaProof, IMO 2024 [Dee24]
2026 : problèmes d'Erdős [nat26] résolus par Aristotle [Ari26], Aletheia [Goo26]
Severini [Sev26]
≈ 0,05% des maths formalisées.
L'IA a faim de corpus vérifié : la formalisation devient application phare.
Massot [Mas21] : outil, pas substitut.

Seuil qualitatif fin 2025 – début 2026

- Passage *maths de compétition* (IMO) → *maths de recherche*.
- Janv. 2026 : problèmes #397, #728, #729 résolus en une semaine (GPT-5.2 Pro + Aristotle).
- Févr. 2026 : Aletheia (Gemini 3 Deep Think) résout 4 problèmes dont #1051.
- ≈ 100 énoncés basculés en « résolus » depuis octobre 2025.

Severini — inversion du moteur

- Moteur plus seulement scientifique : aussi *économique/infrastructurel*.
- Labos d'IA ont un intérêt direct à financer la formalisation.

Nuance Massot

- Formalisation = outil, pas substitut.
- Pluralité de styles (informel / semi-formel / mécanisé) qui coexistent.

Au-delà des maths : sûreté de l'IA par la preuve

Tegmark & Omohundro [TO23]

Provably Safe Systems — seule voie vers une AGI contrôlable.

Au-delà des maths : sûreté de l'IA par la preuve
Tegmark & Omohundro [TO23]
Provably Safe Systems — seule voie vers une AGI contrôlable.

Reconstruire l'argument à voix haute

- RLHF, monitoring : garanties *statistiques*.
- À grande échelle, « 1 cas sur 1000 » devient inacceptable.
- Seule la preuve formelle fournit l'assurance requise.
- Ce qui rend l'approche faisable : c'est l'IA qui rédige les preuves.

Tension à annoncer

- Prouver « pas de stack overflow » $\neq$ prouver « ne pas nuire ».
- Le problème de la *spécification* reste entier (traité à l'acte II).

Transition vers acte II

- Et si le cadre technique lui-même était fragile ?

Au-delà des maths : sûreté de l'IA par la preuve

Tegmark & Omohundro [TO23]

Provably Safe Systems — seule voie vers une AGI contrôlable.

1. Alignement (RLHF, monitoring) → garanties *statistiques*
2. Preuve formelle → garantie *mathématique*
3. L'IA rend l'approche *faisable* à grande échelle

Au-delà des maths : sûreté de l'IA par la preuve
Tegmark & Omohundro [TO23]
Provably Safe Systems — seule voie vers une AGI contrôlable.
Alignement (RLHF, monitoring) → garanties statistiques
Preuve formelle → garantie mathématique
L'IA rend l'approche faisable à grande échelle

Reconstruire l'argument à voix haute

- RLHF, monitoring : garanties *statistiques*.
- À grande échelle, « 1 cas sur 1000 » devient inacceptable.
- Seule la preuve formelle fournit l'assurance requise.
- Ce qui rend l'approche faisable : c'est l'IA qui rédige les preuves.

Tension à annoncer

- Prouver « pas de stack overflow » $\neq$ prouver « ne pas nuire ».
- Le problème de la *spécification* reste entier (traité à l'acte II).

Transition vers acte II

- Et si le cadre technique lui-même était fragile ?

Au-delà des maths : sûreté de l'IA par la preuve

Tegmark & Omohundro [TO23]

Provably Safe Systems — seule voie vers une AGI contrôlable.

1. Alignement (RLHF, monitoring) → garanties *statistiques*
2. Preuve formelle → garantie *mathématique*
3. L'IA rend l'approche *faisable* à grande échelle

La promesse ultime

Vérification + IA = sûreté des systèmes critiques, *y compris* des IA.

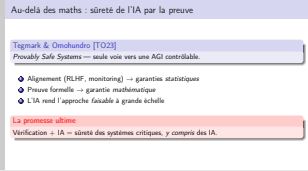

Reconstruire l'argument à voix haute

- RLHF, monitoring : garanties *statistiques*.
- À grande échelle, « 1 cas sur 1000 » devient inacceptable.
- Seule la preuve formelle fournit l'assurance requise.
- Ce qui rend l'approche faisable : c'est l'IA qui rédige les preuves.

Tension à annoncer

- Prouver « pas de stack overflow » $\neq$ prouver « ne pas nuire ».
- Le problème de la *spécification* reste entier (traité à l'acte II).

Transition vers acte II

- Et si le cadre technique lui-même était fragile ?

Qui vérifie le noyau ?

Si on fonde la sûreté sur la preuve, tout repose sur le vérificateur — commençons par lui.

Critère de de Bruijn [Bru80]

Noyau *minimal* : vérificateur de λ-termes, auditable par un humain.

- Pas de confiance dans les tactiques
- Confiance dans le **noyau** ($\sim$ quelques milliers de lignes)
- Noyau correct $\Rightarrow$ toute preuve acceptée est correcte

Qui vérifie le noyau ?
Si on fonde la sûreté sur la preuve, tout repose sur le vérificateur — commençons par lui.
Critère de de Bruijn [Bru80]
Noyau minimal : vérificateur de λ-termes, auditable par un humain.
Pas de confiance dans les tactiques
Confiance dans le noyau (∼ quelques milliers de lignes)
Noyau correct ⇒ toute preuve acceptée est correcte

Transition courte — ne pas s'attarder

- Si la sûreté repose sur la preuve : examiner le vérificateur.

Point d'architecture à expliciter

- Tactiques arbitrairement complexes $\rightarrow$ pas grave (produisent des termes).
- Toute la confiance est concentrée dans le noyau.

Régression à tracer au tableau

- Noyau $\rightarrow$ compilateur du noyau $\rightarrow$ matériel.
- Thématisée par Thompson (1984) — slide suivante.

Qui vérifie le noyau ?

Si on fonde la sûreté sur la preuve, tout repose sur le vérificateur — commençons par lui.

Critère de de Bruijn [Bru80]

Noyau *minimal* : vérificateur de λ-termes, auditable par un humain.

- Pas de confiance dans les tactiques
- Confiance dans le **noyau** ($\sim$ quelques milliers de lignes)
- Noyau correct $\Rightarrow$ toute preuve acceptée est correcte

Régression

Noyau correct ? Compilateur du noyau ? Matériel ?

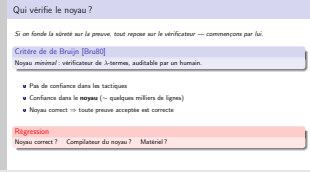

Transition courte — ne pas s'attarder

- Si la sûreté repose sur la preuve : examiner le vérificateur.

Point d'architecture à expliciter

- Tactiques arbitrairement complexes $\rightarrow$ pas grave (produisent des termes).
- Toute la confiance est concentrée dans le noyau.

Régression à tracer au tableau

- Noyau $\rightarrow$ compilateur du noyau $\rightarrow$ matériel.
- Thématisée par Thompson (1984) — slide suivante.

Thompson 1984 — *Reflections on Trusting Trust*

Ken Thompson, Turing Award [Tho84].

Compilateur C malveillant :

1. porte dérobée injectée dans `login`
2. s'auto-reproduit à la compilation d'un compilateur

Source *propre* → binaire *compromis*.

Thèse

« You can't trust code that you did not totally create yourself. »

Conséquence

La vérification *déplace* la confiance — elle ne l'élimine pas.

Thompson 1984 — *Reflections on Trusting Trust*
Ken Thompson, Turing Award [Tho84].
Compilateur C malveillant :
1. porte dérobée injectée dans `login`
2. s'auto-reproduit à la compilation d'un compilateur
Source *propre* → binaire *compromis*.
Thèse
« You can't trust code that you did not totally create yourself. »
Conséquence
La vérification *déplace* la confiance — elle ne l'élimine pas.

Portée de l'argument

- Pas un bug particulier : *structure générale* de la confiance en informatique.
- Origine de la notion de *trusted computing base*.

Justification a posteriori du critère de de Bruijn

- Minimiser le noyau = minimiser la surface de confiance.
- Mais cette surface n'est *jamais nulle* — un petit noyau s'exécute toujours quelque part de non prouvé.

Préparer la chute

- 2026 donne des exemples concrets à chaque niveau qui craque.

Le retournement 2026 : l'IA casse le cadre

Mythos [Ant26]

Anthropic, avril 2026

- 0-days dans OpenBSD, Linux, FreeBSD
- Milliers de vulnérabilités
- Source reconstruite depuis binaires

L'IA comme attaquant de classe nouvelle.

`False` dans Rocq [Roc26 ; Sté26]

Mars 2026

- Sept preuves de `False` via bugs indépendants
- Guard checker, modules
- IA + humain, avec l'équipe Rocq

Le noyau minimal n'est pas infaillible.

Watchers [Gop26]

`lean-zip`, **avril 2026**

- Décodeur ZIP prouvé en Lean 4
- Parseur non vérifié : overflow
- Un 2e bug hors-spec
- Trouvés par Claude Code

Preuve OK, runtime cassé, spec incomplète.

Trois niveaux, trois fractures — toutes mises au jour par l'IA.

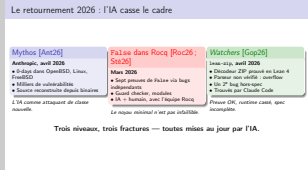

Slide centrale — prendre le temps.

Mythos

- Techniques : RCE, ROP, JIT ; bugs retrouvés 27 ans après leur introduction.
- *Retourne Tegmark* : l'IA qui vérifie est aussi celle qui casse — course, non victoire.

`False` dans Rocq

- Bugs exploités : *guard checker* + gestion des modules.
- Collaboration humains + Claude Opus 4.6 (Stérin), concertée avec l'équipe Rocq.
- Distinction clé : *auditabilité* $\neq$ *correction*.

Watchers

- Décodeur prouvé ; le code *appelant* (`lean_alloc_sarray`) ne l'est pas $\rightarrow$ heap overflow.
- Second bug : comportement exploité *non couvert* par la spécification — ce n'est donc pas seulement un problème de runtime.

Trois niveaux de confiance, ré-examinés

1. Spécification	*Formaliser les valeurs ?*
2. Noyau	*`False` (Opus 4.6) [Roc26]*
3. Runtime / compilateur / matériel	*Overflow Lean [Gop26]*

À retenir

Pas de garantie absolue. Garanties *relatives* à des hypothèses explicites.

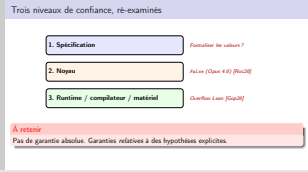

Recadrage, pas réfutation

- Vérification formelle reste l'outil le plus puissant pour les garanties logicielles.
- Ses garanties sont *conditionnelles* à des hypothèses explicites.

Analogie à développer

- Prouver en théorie des ensembles = prouver *si* ZFC cohérent.
- Prouver en Rocq = prouver *si* noyau correct $\wedge$ runtime fidèle $\wedge$ matériel sain.

Formule clé à noter au tableau

- Pas « peut-on faire confiance ? ».
- Mais « à quoi fait-on confiance, et est-ce justifié ? ».

Bilan — six semaines

Savoir-faire :

- Habiter un type
- Déduction naturelle
- Rocq : `Inductive`, `Fixpoint`, `induction`

Philosophiquement :

- **Curry-Howard** : preuves = programmes
- **Constructivisme**
- **Vérificationnisme**
- **Mécanisation** du travail épistémique
- **Confiance** déplacée, pas supprimée

Pour la suite

DM — rev ∘ rev = id — 25 avril.
Calculemus, mais lucidement.

Bilan — six semaines
Savoir-faire :
Habiter un type
Déduction naturelle
Rocq : Inductive, Fixpoint, induction
Philosophiquement :
Curry-Howard : preuves = programmes
Constructivisme
Vérificationnisme
Mécanisation du travail épistémique
Confiance déplacée, pas supprimée
Pour la suite
DM — rev ∘ rev = id — 25 avril.
Calculemus, mais lucidement.

Insister

- Double niveau (technique + philosophique) tenu sur 6 semaines.
- « Confiance déplacée, pas supprimée » — thèse centrale du cours.

Cadre historique

- Tournant formel s'accélère ; questions épistémologiques loin d'être résolues.
- Les philosophes ont leur mot à dire dans ce débat.

Clore

- DM : `rev (rev l) = l`, rendu le 25 avril.
- *Calculemus, mais lucidement.*
- Remerciements.

Bibliographie I

[25] *Professor Kevin Buzzard : What Is Formalization and Why Does It Matter ?* 1er oct. 2025. URL : https://www.youtube.com/watch?v=0fy8VURvwac (visité le 17/03/2026).

[al21] Peter Scholze et al. "Liquid Tensor Experiment". In : (2021). url : https://leanprover-community.github.io/liquid/.

[Ant26] Anthropic. *Claude Mythos Preview*. 2026. url : https://red.anthropic.com/2026/mythos-preview/ (visité le 16/04/2026).

[Ari26] Aristotle team (Harmonic) and Neel Somani. *Resolution of Erdős Problem #728 : a writeup of Aristotle's Lean proof*. 2026. arXiv : 2601.07421. url : https://arxiv.org/abs/2601.07421 (visité le 21/04/2026).

[Avi23] Jeremy Avigad. *Mathematics and the Formal Turn*. 4 nov. 2023. doi : 10.48550/arXiv.2311.00007. arXiv : 2311.00007 [math]. url : http://arxiv.org/abs/2311.00007 (visité le 17/03/2026). Prépubl.

Bibliographie I

[25] Professor Kevin Buzzard : What Is Formalization and Why Does It Matter ? 1er oct. 2025. URL : https://www.youtube.com/watch?v=0fy8VURvwac (visité le 17/03/2026).

[al21] Peter Scholze et al. "Liquid Tensor Experiment". In : (2021). url : https://leanprover-community.github.io/liquid/.

[Ant26] Anthropic. Claude Mythos Preview. 2026. url : https://red.anthropic.com/2026/mythos-preview/ (visité le 16/04/2026).

[Ari26] Aristotle team (Harmonic) and Neel Somani. Resolution of Erdős Problem #728 : a writeup of Aristotle's Lean proof. 2026. arXiv : 2601.07421. url : https://arxiv.org/abs/2601.07421 (visité le 21/04/2026).

[Avi23] Jeremy Avigad. Mathematics and the Formal Turn. 4 nov. 2023. doi : 10.48550/arXiv.2311.00007. arXiv : 2311.00007 [math]. url : http://arxiv.org/abs/2311.00007 (visité le 17/03/2026). Prépubl.

Bibliographie II

[Ben17] Christoph Benzmüller. *Universal Reasoning, Rational Argumentation and Human-Machine Interaction*. 28 mars 2017. doi : 10.48550/arXiv.1703.09620. arXiv : 1703.09620 [cs]. url : http://arxiv.org/abs/1703.09620 (visité le 17/03/2026). Prépubl.

[Bru80] N. G. de Bruijn. "The Mathematical Language Automath, Its Usage, and Some of Its Extensions". In : *Synthese* 43.1 (1980), p. 1-29. url : https://doi.org/10.1007/BF00485013.

[Buz25] Kevin Buzzard. *Mathematical Reasoning and the Computer*. 11 fév. 2025. doi : 10.48550/arXiv.2502.07850. arXiv : 2502.07850 [cs]. url : http://arxiv.org/abs/2502.07850 (visité le 17/03/2026). Prépubl.

[Dee24] Google DeepMind. "AlphaProof and AlphaGeometry 2 solve IMO problems". In : (2024). url : https://deepmind.google/discover/blog/ai-solves-imo-problems-at-silver-medal-level/.

Bibliographie II
[Ben17] Christoph Benzmüller. *Universal Reasoning, Rational Argumentation and Human-Machine Interaction*. 28 mars 2017. doi : 10.48550/arXiv.1703.09620. arXiv : 1703.09620 [cs]. url : http://arxiv.org/abs/1703.09620 (visité le 17/03/2026). Prépubl.
[Bru80] N. G. de Bruijn. "The Mathematical Language Automath, Its Usage, and Some of Its Extensions". In : *Synthese* 43.1 (1980), p. 1-29. url : https://doi.org/10.1007/BF00485013.
[Buz25] Kevin Buzzard. *Mathematical Reasoning and the Computer*. 11 fév. 2025. doi : 10.48550/arXiv.2502.07850. arXiv : 2502.07850 [cs]. url : http://arxiv.org/abs/2502.07850 (visité le 17/03/2026). Prépubl.
[Dee24] Google DeepMind. "AlphaProof and AlphaGeometry 2 solve IMO problems". In : (2024). url : https://deepmind.google/discover/blog/ai-solves-imo-problems-at-silver-medal-level/.

Bibliographie III

[Gon08] Georges Gonthier. "Formal Proof—The Four Color Theorem". In : *Notices of the AMS* (2008). url : https://www.ams.org/notices/200811/tx081101382p.pdf.

[Goo26] Google DeepMind. *Aletheia : Autonomous Mathematical Discovery with Gemini 3 Deep Think*. 2026. url : https://deepmind.google/blog/accelerating-mathematical-and-scientific-discovery-with-gemini-deep-think/ (visité le 21/04/2026).

[Gop26] Kiran Gopinathan. *Who Watches the Watchers ? Fuzzing a Formally-Verified ZIP Parser*. 2026. url : https://kirancodes.me/posts/log-who-watches-the-watchers.html (visité le 16/04/2026).

[Hal+17] Thomas Hales et al. "A Formal Proof of the Kepler Conjecture". In : *Forum of Mathematics, Pi* (2017). url : https://doi.org/10.1017/fmp.2017.1.

Bibliographie III

[Gon08] Georges Gonthier. "Formal Proof—The Four Color Theorem". In : Notices of the AMS (2008). url : https://www.ams.org/notices/200811/tx081101382p.pdf.

[Goo26] Google DeepMind. Aletheia : Autonomous Mathematical Discovery with Gemini 3 Deep Think. 2026. url : https://deepmind.google/blog/accelerating-mathematical-and-scientific-discovery-with-gemini-deep-think/ (visité le 21/04/2026).

[Gop26] Kiran Gopinathan. Who Watches the Watchers ? Fuzzing a Formally-Verified ZIP Parser. 2026. url : https://kirancodes.me/posts/log-who-watches-the-watchers.html (visité le 16/04/2026).

[Hal+17] Thomas Hales et al. "A Formal Proof of the Kepler Conjecture". In : Forum of Mathematics, Pi (2017). url : https://doi.org/10.1017/fmp.2017.1.

Bibliographie IV

[Kle+09] Gerwin Klein et al. "seL4 : Formal verification of an OS kernel". In : *SOSP*. 2009. url : https://dl.acm.org/doi/10.1145/1629575.1629596.

[Ler09] Xavier Leroy. "Formal verification of a realistic compiler". In : *Communications of the ACM* 52.7 (2009), p. 107-115. url : https://dl.acm.org/doi/10.1145/1538788.1538814.

[Mas21] Patrick Massot. *Why Formalize Mathematics ?* 5 déc. 2021. url : https://www.imo.universite-paris-saclay.fr/~patrick.massot/files/exposition/why_formalize.pdf.

[nat26] natsothanaphan. "AI contributions to Erdős problems". In : (2026). url : https://github.com/teorth/erdosproblems/wiki/AI-contributions-to-Erd%5C%C5%5C%91s-problems/.

Bibliographie IV

[Kle+09] Gerwin Klein et al. "seL4 : Formal verification of an OS kernel". In : SOSP. 2009. url : https://dl.acm.org/doi/10.1145/1629575.1629596.

[Ler09] Xavier Leroy. "Formal verification of a realistic compiler". In : Communications of the ACM 52.7 (2009), p. 107-115. url : https://dl.acm.org/doi/10.1145/1538788.1538814.

[Mas21] Patrick Massot. Why Formalize Mathematics ? 5 déc. 2021. url : https://www.imo.universite-paris-saclay.fr/~patrick.massot/files/exposition/why_formalize.pdf.

[nat26] natsothanaphan. "AI contributions to Erdős problems". In : (2026). url : https://github.com/teorth/erdosproblems/wiki/AI-contributions-to-Erd%5C%C5%5C%91s-problems/.

Bibliographie V

[Roc26] Rocq Zulip community. *Proof of False Found by Opus 4.6 and mxdys (bbchallenge)*. 2026. url : https://rocq-prover.zulipchat.com/#narrow/channel/237977-Rocq-users/topic/Proof.20of.20false.20found.20by.20Opus.204.2E6.20and.20mxdys.20.28bbchallenge.29/with/580830257 (visité le 16/04/2026).

[Sev26] Simone Severini. *Infrastructure for Mathematics*. 2026. url : https://simoneseverini.github.io/infrastructure-for-mathematics.html (visité le 16/04/2026).

[Sté26] Tristan Stérin. *In Search of Falsehood : AI-Assisted Hunt for Inconsistencies in Rocq*. 2026. url : https://tristan.st/blog/in_search_of_falsehood (visité le 20/04/2026).

[Tho84] Ken Thompson. "Reflections on Trusting Trust". In : *Communications of the ACM* 27.8 (1984), p. 761-763. url : https://dl.acm.org/doi/10.1145/358198.358210.

Bibliographie V

[Roc26] Rocq Zulip community. *Proof of False Found by Opus 4.6 and mxdys (bbchallenge)*. 2026. url : https://rocq-prover.zulipchat.com/#narrow/channel/237977-Rocq-users/topic/Proof.20of.20false.20found.20by.20Opus.204.2E6.20and.20mxdys.20.28bbchallenge.29/with/580830257 (visité le 16/04/2026).

[Sev26] Simone Severini. *Infrastructure for Mathematics*. 2026. url : https://simoneseverini.github.io/infrastructure-for-mathematics.html (visité le 16/04/2026).

[Sté26] Tristan Stérin. *In Search of Falsehood : AI-Assisted Hunt for Inconsistencies in Rocq*. 2026. url : https://tristan.st/blog/in_search_of_falsehood (visité le 20/04/2026).

[Tho84] Ken Thompson. "Reflections on Trusting Trust". In : *Communications of the ACM* 27.8 (1984), p. 761-763. url : https://dl.acm.org/doi/10.1145/358198.358210.

Bibliographie VI

[TO23] Max Tegmark et Steve Omohundro. *Provably Safe Systems : The Only Path to Controllable AGI*. 5 sept. 2023. doi : 10.48550/arXiv.2309.01933. arXiv : 2309.01933 [cs]. url : http://arxiv.org/abs/2309.01933 (visité le 16/04/2026).

Bibliographie VI
[TO23] Max Tegmark et Steve Omohundro. *Provably Safe Systems : The Only Path to Controllable AGI*. 5 sept. 2023. doi : 10.48550/arXiv.2309.01933. arXiv : 2309.01933 [cs]. url : http://arxiv.org/abs/2309.01933 (visité le 16/04/2026).